第一章　数据的类型

在开始分析之前，先要弄清楚手里拿到的数据属于哪一类。不同类型的数据，能用的统计方法和可视化方式完全不同。

1. 数值型数据（quantitative）：可以直接做加减乘除的量，例如身高、成绩、销售额。它又分为连续型和离散型：连续型可以取任意小数（如温度），离散型只能取整数（如人数）。
2. 分类型数据（nominal）：只是标签，没有大小顺序，例如专业名称、血型、城市。对分类型数据计算平均值没有意义。
3. 顺序型数据（ordinal）：有顺序但间隔不确定，例如满意度五级量表、学历层次。可以比较大小，但不能直接相减。
4. 常见错误：把学号当成数值型去做平均。学号只是标识，属于分类型。

第二章　描述统计

描述统计用几个数字概括一批数据。选错指标，结论会完全相反。

1. 均值（mean）：所有数值之和除以个数。对极端值非常敏感，一条异常记录就能把它拉偏。
2. 中位数（median）：排序后位于中间的数。不受极端值影响，收入、房价这类偏态分布数据通常用中位数更能代表典型水平。
3. 众数（mode）：出现次数最多的值。分类型数据唯一能用的集中趋势指标。
4. 标准差（standard deviation）：衡量数据分散程度。标准差大，说明个体差异明显；标准差小，说明数据集中在均值附近。
5. 经验判断：当均值和中位数差距明显时，说明数据存在偏态或异常值，此时优先报告中位数，并说明原因。

第三章　可视化选择

图表不是越漂亮越好，而是要和数据类型、分析目的匹配。

1. 直方图（histogram）：看连续数值型数据的分布形状，例如成绩分布是否呈双峰。注意它和柱状图不同：直方图的横轴是连续的区间。
2. 箱线图（box plot）：一次展示中位数、四分位数和异常值，适合比较多组的分布差异。
3. 散点图（scatter plot）：看两个数值型变量之间的关系，例如学习时长与成绩是否同向变化。
4. 柱状图（bar chart）：比较不同类别的数量，横轴是分类型标签。
5. 选择原则：先判断数据类型，再判断要看分布、比较还是关系，最后才考虑配色与美化。